

Análisis Numérico de Ecuaciones Diferenciales

Proyecto Final

Redes Neuronales Informadas por la Física (PINNs):

Problema Inverso de Parámetros

Pista B

Ecuación de difusión 1D con coeficiente desconocido

Basado en: Raissi, Perdikaris y Karniadakis (2019),
J. Comput. Phys. 378:686–707

June 15, 2026

Contents

1	Introducción y Planteamiento del Problema	2
2	Metodología	2
2.1	Arquitectura de la red	2
2.2	Función de pérdida	3
2.3	Diferenciación automática	3
2.4	Entrenamiento	3
3	Problema Directo	3
3.1	Convergencia	3
3.2	Solución reconstruida	4
4	Problema Inverso	4
4.1	Convergencia del parámetro	4
4.2	Resultado final	6
4.3	Reconstrucción del campo	6
5	Validación	6
5.1	Comparación con diferencias finitas (Crank-Nicolson)	6
5.2	Estudio de sensibilidad	9
5.3	Validación de plausibilidad física	9
6	Discusión y Limitaciones	9
7	Conclusiones	9

1 Introducción y Planteamiento del Problema

En numerosos fenómenos de transporte, la forma funcional de la EDP es conocida, pero ciertos coeficientes constitutivos permanecen inaccesibles a medición directa. El **problema inverso de parámetros** consiste en inferirlos a partir de observaciones dispersas y ruidosas del campo solución.

Se estudia la **ecuación de difusión unidimensional**:

$$\frac{\partial u}{\partial t} = \lambda \frac{\partial^2 u}{\partial x^2}, \quad (x, t) \in [0, 1]^2, \quad (1)$$

con condición inicial $u(x, 0) = \sin(\pi x)$ y condiciones Dirichlet homogéneas $u(0, t) = u(1, t) = 0$. La solución analítica exacta es

$$u(x, t) = \sin(\pi x) e^{-\lambda \pi^2 t}. \quad (2)$$

El parámetro $\lambda > 0$ es **incógnita**; el objetivo es recuperarlo a partir de $N_d = 100$ observaciones con 1 % de ruido gaussiano.




Figure 1: Condición inicial del problema: $u(x, 0) = \sin(\pi x)$ en el dominio $[0, 1]$. Esta función suave de amplitud unitaria es la referencia para todos los experimentos presentados en este informe.

2 Metodología

2.1 Arquitectura de la red

Se implementó una PINN como subclase de `tf.keras.Model` en TensorFlow 2.x: 3 capas ocultas de 40 neuronas, activación tanh, inicialización Glorot normal. El coeficiente $\hat{\lambda}$ se declara como `tf.Variable` escalar con restricción $\hat{\lambda} \geq 10^{-6}$, inicializado en $\hat{\lambda}_0 = 0.5$.




Figure 2: Distribución de los $N_d = 100$ puntos de observación sintéticos en el dominio $(x, t) \in [0, 1]^2$, coloreados por el valor de u observado. Las observaciones se generaron evaluando la solución analítica (2) con $\lambda = 0.1$ y añadiendo ruido gaussiano del 1 %.

2.2 Función de pérdida

$$\mathcal{L}(\theta, \hat{\lambda}) = w_f \mathcal{L}_f + \mathcal{L}_{ic} + \mathcal{L}_b + w_d \mathcal{L}_d, \quad w_f = 1, \quad w_d = 10. \quad (3)$$

2.3 Diferenciación automática

Se usaron tapes anidados (`tape1` interno y `tape2` externo) para calcular correctamente $\partial^2 \tilde{u} / \partial x^2$.

2.4 Entrenamiento

Adam, $\eta = 10^{-3}$, 8000 épocas. $\hat{\lambda}$ y θ se optimizan conjuntamente.

3 Problema Directo

3.1 Convergencia

La Figura 3 muestra la evolución de las componentes de la función de pérdida durante el entrenamiento del problema directo (con λ conocido). Las tres curvas descienden de forma consistente, lo que confirma la convergencia simultánea del residuo PDE y de las condiciones de contorno e iniciales.




Figure 3: Evolución de la función de pérdida durante el entrenamiento del problema directo, descompuesta en pérdida total, residuo de la PDE y términos de condición inicial y de contorno (IC+BC), representada en escala logarítmica.

3.2 Solución reconstruida

La Figura 4 compara la solución analítica con la predicción del PINN y muestra el mapa de error absoluto resultante. El error máximo se concentra en la región de mayor gradiente temporal ($t \approx 0$, $x \approx 0.5$), manteniéndose dentro del orden 10^{-3} .




Figure 4: Validación del problema directo: solución analítica (izquierda), predicción del PINN (centro) y mapa de error absoluto $|u_{\text{PINN}} - u_{\text{anal}}|$ (derecha) en el dominio $[0, 1]^2$.

4 Problema Inverso

4.1 Convergencia del parámetro

Las Figuras 5 y 6 documentan la convergencia del problema inverso. En particular, la Figura 5 muestra que $\hat{\lambda}$ parte de 0.5 y converge al valor real $\lambda = 0.1$ en las primeras 500 épocas, permaneciendo estable durante el resto del entrenamiento.

La Figura 7 complementa la anterior mostrando exclusivamente la trayectoria de $\hat{\lambda}$ en escala lineal, lo que permite apreciar la precisión de la estimación final.




Figure 5: Evolución conjunta del parámetro estimado $\hat{\lambda}$ (eje izquierdo, escala lineal) y de la pérdida total (eje derecho, escala logarítmica) durante el entrenamiento del problema inverso. La línea roja discontinua indica el valor real $\lambda_{\text{real}} = 0.1$.




Figure 6: Evolución de la pérdida total durante el entrenamiento del problema inverso en escala logarítmica. El descenso monótono general, interrumpido únicamente por un transitorio en torno al paso 8, refleja la dinámica no convex del paisaje de optimización.




Figure 7: Convergencia del parámetro estimado $\hat{\lambda}$ hacia el valor real $\lambda = 0.1$ a lo largo del entrenamiento del problema inverso. El estimador alcanza y mantiene una proximidad inferior al 0.2% a partir de las primeras 1000 épocas.

4.2 Resultado final

Table 1: Resultado del problema inverso.

Magnitud	Valor
λ_{real}	0.10000
$\hat{\lambda}$ estimado	0.10017
Error relativo	0.17 %
$ \nabla_{\hat{\lambda}} \mathcal{L} $ final	1.58×10^{-6}

4.3 Reconstrucción del campo

La Figura 8 muestra que el campo $u(x, t)$ reconstruido con el parámetro inferido $\hat{\lambda} = 0.10017$ es prácticamente indistinguible de la solución analítica, con un error absoluto máximo inferior a 7.2×10^{-3} .

5 Validación

5.1 Comparación con diferencias finitas (Crank-Nicolson)

Las Figuras 9 y 10 presentan cortes temporales que permiten una inspección visual directa del acuerdo entre los tres métodos. En ambos casos, las curvas de la solución analítica, Crank-Nicolson y PINN son prácticamente superponibles en toda la ventana temporal.




Figure 8: Validación del problema inverso: predicción del PINN con $\hat{\lambda} = 0.10017$ (izquierda), solución analítica correspondiente (centro) y mapa de error absoluto $|u_{\text{PINN}} - u_{\text{anal}}|$ (derecha) en el dominio $[0, 1]^2$.

Table 2: Errores L^2 relativos de la validación contra Crank-Nicolson.

Comparación	Problema Directo	Problema Inverso ($\hat{\lambda} = 0.10017$)
CN vs. analítica	6.711×10^{-3}	6.737×10^{-3}
PINN vs. analítica	1.470×10^{-3}	1.565×10^{-3}
CN vs. PINN	7.453×10^{-3}	7.250×10^{-3}




Figure 9: Comparación de cortes temporales en el problema directo para $t \in \{0, 0.25, 0.5, 0.75, 1.0\}$: solución analítica (negro sólido), Crank-Nicolson (azul discontinuo) y PINN (rojo punteado). Las tres curvas son visualmente indistinguibles en todos los instantes considerados.




Figure 10: Comparación de cortes temporales en el problema inverso para $t \in \{0, 0.25, 0.5, 0.75, 1.0\}$: solución analítica (negro sólido), Crank-Nicolson (azul discontinuo) y PINN inverso con $\hat{\lambda} = 0.10017$ (rojo punteado).

Table 3: Error relativo en $\hat{\lambda}$ (%) — media sobre tres semillas (rango entre paréntesis).

N_d	Ruido 0 %	Ruido 1 %
20	0.18 % (0.03–0.26)	0.35 % (0.11–0.52)
50	0.23 % (0.17–0.29)	0.12 % (0.07–0.21)
100	0.21 % (0.10–0.29)	0.65 % (0.53–0.80)
200	0.19 % (0.14–0.28)	0.26 % (0.07–0.65)




Figure 11: Estudio de sensibilidad del problema inverso: error relativo en $\hat{\lambda}$ (panel izquierdo) y error L^2 relativo del campo reconstruido (panel derecho) en función del número de observaciones N_d , para dos niveles de ruido ($\sigma \in \{0\%, 1\%\}$). La línea gris discontinua marca el umbral de referencia del 1 %. En todos los escenarios evaluados, ambas métricas se mantienen por debajo de dicho umbral.

5.2 Estudio de sensibilidad

5.3 Validación de plausibilidad física

1. **Positividad:** $\hat{\lambda} \leftarrow \max(\hat{\lambda}, 10^{-6})$ tras cada paso.
2. **Consistencia del campo:** reproduce el decaimiento exponencial analítico.
3. **Diagnóstico de gradiente:** $|\nabla_{\hat{\lambda}} \mathcal{L}|$ consistente durante todo el entrenamiento.

6 Discusión y Limitaciones

Paisaje de optimización no convexo.

Se detectó un mínimo local espurio ($N_d = 50$, ruido 0 %, error $L^2 = 4.12 \times 10^{-2}$) no reproducido en corridas posteriores, lo que motiva el uso de múltiples inicializaciones.

Ausencia de tendencia monótona con N_d .

El error en $\hat{\lambda}$ oscila entre 0.18 % y 0.23 % para ruido nulo, indicando que el cuello de botella es el optimizador, no la cantidad de datos.

Variabilidad con ruido.

Con ruido del 1 %, la variabilidad inter-semilla aumenta, especialmente en $N_d = 100$.

Extensión a Fokker-Planck.

Extensión natural: inferir deriva y difusión conjuntamente siguiendo Chen et al. (2021).

7 Conclusiones

1. λ recuperado con error relativo **0.17 %** (umbral: 1 %).
2. Error L^2 del campo: 1.57×10^{-3} (objetivo: $\sim 10^{-3}$).
3. PINN supera a Crank-Nicolson ($N_x = 99$, $N_t = 1000$) en precisión.
4. Robusto para $N_d \geq 20$ y ruido hasta 1 % — 24/24 configuraciones bajo umbral.

References

- [1] Raissi, M., Perdikaris, P., & Karniadakis, G.E. (2019). Physics-informed neural networks. *J. Comput. Phys.*, 378, 686–707.

- [2] Karniadakis, G.E. et al. (2021). Physics-informed machine learning. *Nature Reviews Physics*, 3, 422–440.
- [3] Chen, X. et al. (2021). Solving inverse stochastic problems via Fokker-Planck and PINNs. *SIAM J. Sci. Comput.*
- [4] Krishnapriyan, A.S. et al. (2021). Failure modes in PINNs. *NeurIPS*, 34.