

# Análisis Numérico de Ecuaciones Diferenciales

Proyecto Final

## Redes Neuronales Informadas por la Física (PINNs):

### Problema Inverso de Parámetros

Pista B

*Ecuación de difusión 1D con coeficiente desconocido*

Basado en: Raissi, Perdikaris y Karniadakis (2019),  
*J. Comput. Phys.* 378:686–707

June 15, 2026

# Contents

|          |                                                                |          |
|----------|----------------------------------------------------------------|----------|
| <b>1</b> | <b>Introducción y Planteamiento del Problema</b>               | <b>2</b> |
| <b>2</b> | <b>Metodología</b>                                             | <b>3</b> |
| 2.1      | Arquitectura de la red . . . . .                               | 3        |
| 2.2      | Función de pérdida . . . . .                                   | 3        |
| 2.3      | Diferenciación automática . . . . .                            | 3        |
| 2.4      | Entrenamiento . . . . .                                        | 3        |
| <b>3</b> | <b>Problema Directo</b>                                        | <b>4</b> |
| 3.1      | Convergencia . . . . .                                         | 4        |
| 3.2      | Solución reconstruida . . . . .                                | 4        |
| <b>4</b> | <b>Problema Inverso</b>                                        | <b>5</b> |
| 4.1      | Convergencia del parámetro . . . . .                           | 5        |
| 4.2      | Resultado final . . . . .                                      | 5        |
| 4.3      | Reconstrucción del campo . . . . .                             | 6        |
| <b>5</b> | <b>Validación</b>                                              | <b>6</b> |
| 5.1      | Comparación con diferencias finitas (Crank-Nicolson) . . . . . | 6        |
| 5.2      | Estudio de sensibilidad . . . . .                              | 7        |
| 5.3      | Validación de plausibilidad física . . . . .                   | 7        |
| <b>6</b> | <b>Discusión y Limitaciones</b>                                | <b>8</b> |
| <b>7</b> | <b>Conclusiones</b>                                            | <b>8</b> |

# 1 Introducción y Planteamiento del Problema

En numerosos fenómenos de transporte, la forma funcional de la EDP es conocida, pero ciertos coeficientes constitutivos permanecen inaccesibles a medición directa. El **problema inverso de parámetros** consiste en inferirlos a partir de observaciones dispersas y ruidosas del campo solución.

Se estudia la **ecuación de difusión unidimensional**:

$$\frac{\partial u}{\partial t} = \lambda \frac{\partial^2 u}{\partial x^2}, \quad (x, t) \in [0, 1]^2, \quad (1)$$

con condición inicial  $u(x, 0) = \sin(\pi x)$  y condiciones Dirichlet homogéneas  $u(0, t) = u(1, t) = 0$ . La solución analítica exacta es

$$u(x, t) = \sin(\pi x) e^{-\lambda \pi^2 t}. \quad (2)$$

El parámetro  $\lambda > 0$  es **incógnita**; el objetivo es recuperarlo a partir de  $N_d = 100$  observaciones con 1 % de ruido gaussiano.

**FIGURA 1 — Condición inicial  $\sin(\pi x)$**

Figure 1: Condición inicial  $u(x, 0) = \sin(\pi x)$  utilizada en todos los experimentos.

**FIGURA 2 — Datos observados (100 puntos con 1% de ruido)**

Figure 2: Distribución de los  $N_d = 100$  puntos de observación en el dominio  $(x, t) \in [0, 1]^2$ , coloreados por el valor de  $u$  observado con 1% de ruido gaussiano.

## 2 Metodología

### 2.1 Arquitectura de la red

Se implementó una PINN como subclase de `tf.keras.Model` en TensorFlow 2.x: 3 capas ocultas de 40 neuronas, activación tanh, inicialización Glorot normal. El coeficiente  $\hat{\lambda}$  se declara como `tf.Variable` escalar con restricción  $\hat{\lambda} \geq 10^{-6}$ , inicializado en  $\hat{\lambda}_0 = 0.5$ .

### 2.2 Función de pérdida

$$\mathcal{L}(\theta, \hat{\lambda}) = w_f \mathcal{L}_f + \mathcal{L}_{ic} + \mathcal{L}_b + w_d \mathcal{L}_d, \quad w_f = 1, \quad w_d = 10. \quad (3)$$

### 2.3 Diferenciación automática

Se usaron tapes anidados (`tape1` interno y `tape2` externo) para calcular correctamente  $\partial^2 \tilde{u} / \partial x^2$ .

### 2.4 Entrenamiento

Adam,  $\eta = 10^{-3}$ , 8000 épocas.  $\hat{\lambda}$  y  $\theta$  se optimizan conjuntamente.

### 3 Problema Directo

#### 3.1 Convergencia

**FIGURA 3 — Convergencia problema directo (pérdida total, PDE, IC+BC)**

Figure 3: Convergencia del problema directo: pérdida total, residuo PDE y condiciones de contorno/iniciales en escala logarítmica.

#### 3.2 Solución reconstruida

**FIGURA 4 — Solución directa: Analítica | PINN | Error absoluto (mapa de color)**

Figure 4: Problema directo: solución analítica (izquierda), solución PINN (centro) y error absoluto (derecha) en el dominio  $[0, 1]^2$ .

## 4 Problema Inverso

### 4.1 Convergencia del parámetro




Figure 5: Evolución conjunta de  $\hat{\lambda}$  y la pérdida total durante el entrenamiento del problema inverso. La línea roja discontinua indica  $\lambda_{\text{real}} = 0.1$ .




Figure 6: Evolución de la pérdida total durante el entrenamiento del problema inverso en escala logarítmica.

### 4.2 Resultado final

Table 1: Resultado del problema inverso.

| Magnitud                                     | Valor                 |
|----------------------------------------------|-----------------------|
| $\lambda_{\text{real}}$                      | 0.10000               |
| $\hat{\lambda}$ estimado                     | 0.10017               |
| Error relativo                               | <b>0.17 %</b>         |
| $ \nabla_{\hat{\lambda}} \mathcal{L} $ final | $1.58 \times 10^{-6}$ |

### 4.3 Reconstrucción del campo

**FIGURA 7 — Campo inverso: PINN ( $\hat{\lambda} = 0.10017$ ) | Analítica | Error absoluto**

Figure 7: Problema inverso: solución PINN con  $\hat{\lambda} = 0.10017$  (izquierda), solución analítica (centro) y error absoluto (derecha).

## 5 Validación

### 5.1 Comparación con diferencias finitas (Crank-Nicolson)

Table 2: Errores  $L^2$  relativos de la validación contra Crank-Nicolson.

| Comparación        | Problema Directo       | Problema Inverso ( $\hat{\lambda} = 0.10017$ ) |
|--------------------|------------------------|------------------------------------------------|
| CN vs. analítica   | $6.711 \times 10^{-3}$ | $6.737 \times 10^{-3}$                         |
| PINN vs. analítica | $1.470 \times 10^{-3}$ | $1.565 \times 10^{-3}$                         |
| CN vs. PINN        | $7.453 \times 10^{-3}$ | $7.250 \times 10^{-3}$                         |

**FIGURA 8 — Cortes temporales CN: problema DIRECTO  
(5 paneles:  $t = 0, 0.25, 0.5, 0.75, 1.0$ ; curvas Analítica, CN, PINN)**

Figure 8: Problema directo: cortes temporales en  $t \in \{0, 0.25, 0.5, 0.75, 1.0\}$  para la solución analítica, Crank-Nicolson y PINN.

**FIGURA 9 — Cortes temporales CN: problema INVERSO**  
**(5 paneles:  $t = 0, 0.25, 0.5, 0.75, 1.0$ ; curvas Analítica, CN, PINN Inverso;**  
**título incluye  $\hat{\lambda} = 0.10017$ )**

Figure 9: Problema inverso: cortes temporales en  $t \in \{0, 0.25, 0.5, 0.75, 1.0\}$  para la solución analítica, Crank-Nicolson y PINN ( $\hat{\lambda} = 0.10017$ ).

## 5.2 Estudio de sensibilidad

Table 3: Error relativo en  $\hat{\lambda}$  (%) — media sobre tres semillas (rango entre paréntesis).

| $N_d$ | Ruido 0 %          | Ruido 1 %          |
|-------|--------------------|--------------------|
| 20    | 0.18 % (0.03–0.26) | 0.35 % (0.11–0.52) |
| 50    | 0.23 % (0.17–0.29) | 0.12 % (0.07–0.21) |
| 100   | 0.21 % (0.10–0.29) | 0.65 % (0.53–0.80) |
| 200   | 0.19 % (0.14–0.28) | 0.26 % (0.07–0.65) |

**FIGURA 10 — Estudio de sensibilidad**  
**(2 paneles: error en  $\hat{\lambda}$  vs  $N_d$  | error  $L^2$  vs  $N_d$ ;**  
**dos curvas por panel: Ruido 0% y Ruido 1%; línea umbral 1%)**

Figure 10: Estudio de sensibilidad: error relativo en  $\hat{\lambda}$  (izquierda) y error  $L^2$  relativo del campo (derecha) en función de  $N_d$ , para  $\sigma \in \{0\%, 1\%\}$ . Línea gris: umbral del 1 %.

## 5.3 Validación de plausibilidad física

1. **Positividad:**  $\hat{\lambda} \leftarrow \max(\hat{\lambda}, 10^{-6})$  tras cada paso.
2. **Consistencia del campo:** reproduce el decaimiento exponencial analítico.



3. **Diagnóstico de gradiente:**  $|\nabla_{\hat{\lambda}} \mathcal{L}|$  consistente durante todo el entrenamiento.

## 6 Discusión y Limitaciones

### Paisaje de optimización no convexo.

Se detectó un mínimo local espurio ( $N_d = 50$ , ruido 0 %, error  $L^2 = 4.12 \times 10^{-2}$ ) no reproducido en corridas posteriores, lo que motiva el uso de múltiples inicializaciones.

### Ausencia de tendencia monótona con $N_d$ .

El error en  $\hat{\lambda}$  oscila entre 0.18 % y 0.23 % para ruido nulo, indicando que el cuello de botella es el optimizador, no la cantidad de datos.

### Variabilidad con ruido.

Con ruido del 1 %, la variabilidad inter-semilla aumenta, especialmente en  $N_d = 100$ .

### Extensión a Fokker-Planck.

Extensión natural: inferir deriva y difusión conjuntamente siguiendo Chen et al. (2021).

## 7 Conclusiones

1.  $\lambda$  recuperado con error relativo **0.17 %** (umbral: 1 %).
2. Error  $L^2$  del campo:  $1.57 \times 10^{-3}$  (objetivo:  $\sim 10^{-3}$ ).
3. PINN supera a Crank-Nicolson ( $N_x = 99$ ,  $N_t = 1000$ ) en precisión.
4. Robusto para  $N_d \geq 20$  y ruido hasta 1 % — 24/24 configuraciones bajo umbral.

## References

- [1] Raissi, M., Perdikaris, P., & Karniadakis, G.E. (2019). Physics-informed neural networks. *J. Comput. Phys.*, 378, 686–707.
- [2] Karniadakis, G.E. et al. (2021). Physics-informed machine learning. *Nature Reviews Physics*, 3, 422–440.
- [3] Chen, X. et al. (2021). Solving inverse stochastic problems via Fokker-Planck and PINNs. *SIAM J. Sci. Comput.*
- [4] Krishnapriyan, A.S. et al. (2021). Failure modes in PINNs. *NeurIPS*, 34.