

Análisis Numérico de Ecuaciones Diferenciales

Proyecto Final

Redes Neuronales Informadas por la Física (PINNs):

Problema Inverso de Parámetros

Pista B

Ecuación de difusión 1D con coeficiente desconocido

Basado en: Raissi, Perdikaris y Karniadakis (2019),
J. Comput. Phys. 378:686–707

June 14, 2026

Contents

1	Introducción y Planteamiento del Problema	2
2	Metodología	2
2.1	Arquitectura de la red	2
2.2	Función de pérdida	3
2.3	Diferenciación automática	3
2.4	Entrenamiento	3
3	Problema Directo	4
3.1	Convergencia	4
3.2	Solución reconstruida	4
4	Problema Inverso	5
4.1	Convergencia del parámetro	5
4.2	Resultado final	6
4.3	Reconstrucción del campo	6
5	Validación	7
5.1	Comparación con diferencias finitas (Crank-Nicolson)	7
5.2	Estudio de sensibilidad	8
5.3	Validación de plausibilidad física	9
6	Discusión y Limitaciones	9
7	Conclusiones	10

1 Introducción y Planteamiento del Problema

En numerosos fenómenos de transporte, la forma funcional de la ecuación diferencial en derivadas parciales (EDP) es conocida, pero ciertos coeficientes constitutivos —como la difusividad térmica o la viscosidad— permanecen inaccesibles a medición directa. El **problema inverso de parámetros** consiste en inferir dichos coeficientes a partir de observaciones dispersas y ruidosas del campo solución, sin recurrir a experimentos costosos ni a discretizaciones globales del dominio.

Se estudia la **ecuación de difusión unidimensional**:

$$\frac{\partial u}{\partial t} = \lambda \frac{\partial^2 u}{\partial x^2}, \quad (x, t) \in [0, 1]^2, \quad (1)$$

con condición inicial $u(x, 0) = \sin(\pi x)$ y condiciones de contorno Dirichlet homogéneas $u(0, t) = u(1, t) = 0$. La solución analítica exacta es

$$u(x, t) = \sin(\pi x) e^{-\lambda \pi^2 t}, \quad (2)$$

lo que permite generar datos sintéticos de referencia y evaluar rigurosamente los errores. El parámetro de difusividad $\lambda > 0$ se trata como **incógnita**; el objetivo es recuperarlo conjuntamente con el campo completo $u(x, t)$ a partir de $N_d = 100$ observaciones distribuidas aleatoriamente en el dominio, contaminadas con un 1% de ruido gaussiano relativo.

2 Metodología

2.1 Arquitectura de la red

Se implementó una PINN (*Physics-Informed Neural Network*) como subclase de `tf.keras.Model` en TensorFlow 2.x, con la siguiente arquitectura:

- **Entradas:** coordenadas $(x, t) \in \mathbb{R}^2$, concatenadas antes de la primera capa oculta.
- **Capas ocultas:** 3 capas densas de 40 neuronas cada una, con activación `tanh`.
- **Salida:** aproximación escalar $\tilde{u}(x, t; \theta)$.
- **Inicialización:** pesos con distribución Glorot normal, adecuada para activaciones `tanh`.

El coeficiente desconocido se declara como `tf.Variable` escalar independiente de los pesos de la red, inicializado en $\hat{\lambda}_0 = 0.5$ (cinco veces el valor real), con restricción explícita de positividad $\hat{\lambda} \geq 10^{-6}$ aplicada tras cada paso de gradiente.

2.2 Función de pérdida

La pérdida total combina cuatro términos:

$$\mathcal{L}(\theta, \hat{\lambda}) = w_f \mathcal{L}_f + \mathcal{L}_{ic} + \mathcal{L}_b + w_d \mathcal{L}_d, \quad (3)$$

donde $w_f = 1$ y $w_d = 10$, y cada término es:

$$\mathcal{L}_f = \frac{1}{N_f} \sum_{i=1}^{N_f} \left(\left. \frac{\partial \tilde{u}}{\partial t} \right|_i - \hat{\lambda} \left. \frac{\partial^2 \tilde{u}}{\partial x^2} \right|_i \right)^2, \quad (4)$$

$$\mathcal{L}_{ic} = \frac{1}{N_{ic}} \sum_{i=1}^{N_{ic}} \left(\tilde{u}(x_i, 0) - \sin(\pi x_i) \right)^2, \quad (5)$$

$$\mathcal{L}_b = \frac{1}{N_{bc}} \sum_{i=1}^{N_{bc}} \left(\tilde{u}(0, t_i)^2 + \tilde{u}(1, t_i)^2 \right), \quad (6)$$

$$\mathcal{L}_d = \frac{1}{N_d} \sum_{i=1}^{N_d} \left(\tilde{u}(x_i^d, t_i^d) - u_i^{\text{obs}} \right)^2. \quad (7)$$

Se emplearon $N_f = 2000$ puntos de colocación y $N_{ic} = N_{bc} = 100$.

2.3 Diferenciación automática

Las derivadas parciales $\partial \tilde{u} / \partial t$ y $\partial^2 \tilde{u} / \partial x^2$ se obtienen mediante diferenciación automática con `tf.GradientTape`. Se utilizaron **tapes anidados** para garantizar el cálculo correcto de la segunda derivada:

- El tape externo (`tape2`) traza $\tilde{u}$ y $\partial \tilde{u} / \partial x$ respecto a x .
- El tape interno (`tape1`) calcula $\partial \tilde{u} / \partial t$ y $\partial \tilde{u} / \partial x$.
- La segunda derivada $\partial^2 \tilde{u} / \partial x^2$ se obtiene aplicando `tape2` sobre $\partial \tilde{u} / \partial x$.

Este diseño evita el error sutil de reutilizar un tape persistente para la segunda derivada, donde la primera derivada no habría sido trazada en el grafo del tape exterior.

2.4 Entrenamiento

Las variables entrenables se componen de los parámetros de la red θ más el escalar $\hat{\lambda}$, optimizados **conjuntamente** mediante Adam con tasa de aprendizaje $\eta = 10^{-3}$ durante 8000 épocas. El gradiente $|\nabla_{\hat{\lambda}} \mathcal{L}|$ se registró en cada iteración como indicador de diagnóstico, permitiendo detectar estancamiento o colapso del parámetro en etapas tempranas del entrenamiento.




Figure 1: Condición inicial $u(x, 0) = \sin(\pi x)$ utilizada en todos los experimentos.




Figure 2: Distribución de los $N_d = 100$ puntos de observación en el dominio $(x, t) \in [0, 1]^2$, coloreados por el valor de u observado con 1% de ruido gaussiano.

3 Problema Directo

Como caso de referencia, se resolvió primero el **problema directo** con $\lambda = 0.1$ conocido, entrenando el PINN únicamente con los términos $\mathcal{L}_f$, $\mathcal{L}_{ic}$ y $\mathcal{L}_b$. Este experimento valida la capacidad de la red para aproximar la solución de la EDP antes de añadir la complejidad del problema inverso.

3.1 Convergencia

La Figura 3 muestra la evolución de la pérdida total y sus componentes durante el entrenamiento. Las tres pérdidas decrecen de forma monótona, con la pérdida total alcanzando $\sim 10^{-4}$ al finalizar las épocas de entrenamiento.




Figure 3: Convergencia del problema directo: pérdida total, residuo PDE y condiciones de contorno/iniciales en escala logarítmica.

3.2 Solución reconstruida

La Figura 4 compara la solución analítica con la aproximación del PINN en el dominio completo, junto con el mapa de error absoluto. El error se concentra en la región $t \rightarrow 1$,

donde la solución es pequeña y el residuo relativo crece.




Figure 4: Problema directo: solución analítica (izquierda), solución PINN (centro) y error absoluto (derecha) en el dominio $[0, 1]^2$.

4 Problema Inverso

4.1 Convergencia del parámetro

La Figura 5 muestra la evolución conjunta de $\hat{\lambda}$ y la pérdida total durante el entrenamiento. El parámetro converge desde $\hat{\lambda}_0 = 0.5$ hasta el vecindario del valor real $\lambda_{\text{real}} = 0.1$ en menos de 1000 épocas, y se estabiliza a partir de la época 2500.




Figure 5: Evolución de $\hat{\lambda}$ durante el entrenamiento del problema inverso. La línea roja discontinua indica el valor real $\lambda_{\text{real}} = 0.1$.




Figure 6: Evolución de la pérdida total durante el entrenamiento del problema inverso en escala logarítmica.

4.2 Resultado final

Al finalizar las 8000 épocas de entrenamiento, los resultados obtenidos fueron:

Table 1: Resultado del problema inverso.

Magnitud	Valor
λ_{real}	0.10000
$\hat{\lambda}$ estimado	0.10017
Error relativo	0.17 %
$ \nabla_{\hat{\lambda}} \mathcal{L} $ final	1.58×10^{-6}

El error relativo de 0.17 % supera con amplio margen el umbral de referencia del 1 % establecido en el enunciado.

4.3 Reconstrucción del campo

La Figura 7 muestra la comparación entre la solución PINN y la analítica evaluadas con $\hat{\lambda} = 0.10017$, junto con el mapa de error absoluto. El patrón de error es similar al del problema directo, con máximos en la región $t \rightarrow 1, x \rightarrow \{0, 1\}$.




Figure 7: Problema inverso: solución PINN con $\hat{\lambda} = 0.10017$ (izquierda), solución analítica (centro) y error absoluto (derecha).

5 Validación

5.1 Comparación con diferencias finitas (Crank-Nicolson)

Como primer control de validación, se implementó un solver de referencia basado en el esquema de **Crank-Nicolson** (CN), incondicionalmente estable, con $N_x = 99$ nodos interiores y $N_t = 1000$ pasos temporales. La comparación se realizó evaluando los tres métodos —solución analítica, CN y PINN— sobre la misma malla, reportando el error L^2 relativo $\|u_A - u_B\|_2 / \|u_A\|_2$.

Table 2: Errores L^2 relativos de la validación contra Crank-Nicolson.

Comparación	Problema Directo	Problema Inverso ($\hat{\lambda} = 0.10017$)
CN vs. analítica	6.711×10^{-3}	6.737×10^{-3}
PINN vs. analítica	1.470×10^{-3}	1.565×10^{-3}
CN vs. PINN	7.453×10^{-3}	7.250×10^{-3}

El PINN supera en precisión al esquema CN respecto a la solución analítica en ambos casos. Esta diferencia se explica por el origen del error en cada método: el CN acumula error de truncación de orden $\mathcal{O}(\Delta x^2, \Delta t^2)$, mientras que el PINN minimiza directamente el residuo continuo de la EDP. La concordancia mutua —diferencias del orden de 10^{-3} — confirma que ambos métodos son consistentes y que la solución del PINN es físicamente correcta.




Figure 8: Problema directo: cortes temporales en $t \in \{0, 0.25, 0.5, 0.75, 1.0\}$ para la solución analítica, Crank-Nicolson y PINN.




Figure 9: Problema inverso: cortes temporales en $t \in \{0, 0.25, 0.5, 0.75, 1.0\}$ para la solución analítica, Crank-Nicolson y PINN ($\hat{\lambda} = 0.10017$).

5.2 Estudio de sensibilidad

Para evaluar la robustez del método, se varió el número de puntos de observación $N_d \in \{20, 50, 100, 200\}$ y el nivel de ruido $\sigma \in \{0\%, 1\%\}$, entrenando cada configuración durante 4000 épocas. El experimento se ejecutó con **tres semillas independientes** para evaluar la variabilidad estocástica.

Table 3: Error relativo en $\hat{\lambda}$ (%) para distintos N_d y niveles de ruido (media sobre tres semillas, con rango entre paréntesis).

N_d	Ruido 0 %	Ruido 1 %
20	0.18 % (0.03–0.26)	0.35 % (0.11–0.52)
50	0.23 % (0.17–0.29)	0.12 % (0.07–0.21)
100	0.21 % (0.10–0.29)	0.65 % (0.53–0.80)
200	0.19 % (0.14–0.28)	0.26 % (0.07–0.65)

En la totalidad de las 24 configuraciones evaluadas, el error en $\hat{\lambda}$ permaneció **por debajo del 1 %**, confirmando que el método recupera el coeficiente de difusión de forma robusta incluso con tan solo 20 observaciones. La Figura 10 muestra la evolución del error en $\hat{\lambda}$ y del error L^2 del campo en función de N_d .




Figure 10: Estudio de sensibilidad: error relativo en $\hat{\lambda}$ (izquierda) y error L^2 del campo reconstruido (derecha) en función de N_d , para dos niveles de ruido. La línea discontinua gris indica el umbral de referencia del 1 %.

5.3 Validación de plausibilidad física

Se realizaron los siguientes controles de plausibilidad:

1. **Positividad del parámetro:** se garantizó $\hat{\lambda} > 0$ en todo el entrenamiento mediante proyección explícita $\hat{\lambda} \leftarrow \max(\hat{\lambda}, 10^{-6})$ tras cada actualización de gradiente.
2. **Consistencia del campo reconstruido:** la solución $\tilde{u}(x, t; \theta^*)$ evaluada con $\hat{\lambda}^*$ reproduce fielmente los contornos y la dinámica de decaimiento exponencial de la solución analítica.
3. **Diagnóstico de gradiente:** el seguimiento de $|\nabla_{\hat{\lambda}} \mathcal{L}|$ a lo largo del entrenamiento confirmó que el parámetro recibió señal de gradiente consistente y no colapsó hacia el límite inferior.

6 Discusión y Limitaciones

Paisaje de optimización no convexo.

La función de pérdida $\mathcal{L}(\theta, \hat{\lambda})$ es altamente no convexa. El estudio de sensibilidad reveló un caso anómalo aislado ($N_d = 50$, ruido 0 %, primera semilla: error $L^2 = 4.12 \times 10^{-2}$) no reproducido en las dos corridas posteriores, que se atribuye a un mínimo local espurio del optimizador. Esto motiva el uso de múltiples inicializaciones en aplicaciones críticas.

Ausencia de tendencia monótona con N_d .

Para ruido nulo, el error en $\hat{\lambda}$ no mejora monótonamente al aumentar N_d , oscilando entre 0.18 % y 0.23 %. Esto indica que el factor limitante es el paisaje de optimización, no la cantidad de datos, al menos en el rango explorado.

Variabilidad con ruido.

Con ruido del 1 %, la variabilidad inter-semilla es mayor, especialmente en $N_d = 100$ (rango de 0.27 puntos porcentuales). Este comportamiento es consistente con la mayor dificultad del problema cuando los datos son ruidosos y la distribución aleatoria de los puntos interactúa con el paisaje de pérdida.

Extensión a Fokker-Planck.

Una extensión natural del método es su aplicación a la ecuación de Fokker-Planck para inferir conjuntamente los términos de deriva y difusión a partir de observaciones de la densidad de probabilidad, siguiendo la línea propuesta por Chen et al. (2021).

7 Conclusiones

Se implementó y validó exitosamente una PINN para resolver el problema inverso de parámetros en la ecuación de difusión 1D. Los resultados principales son:

1. El coeficiente de difusividad λ fue recuperado con un error relativo del **0.17 %**, superando con margen el umbral del 1 % establecido en el enunciado.
2. La reconstrucción del campo $u(x, t)$ alcanzó un error L^2 relativo de 1.57×10^{-3} , consistente con el objetivo de $\sim 10^{-3}$.
3. La validación contra Crank-Nicolson confirmó la consistencia física de la solución; el PINN superó en precisión al esquema clásico con $N_x = 99$ y $N_t = 1000$.
4. El estudio de sensibilidad demostró que el método es robusto para $N_d \geq 20$ y niveles de ruido de hasta el 1 %, con todas las configuraciones evaluadas por debajo del umbral de referencia.

References

- [1] Raissi, M., Perdikaris, P., & Karniadakis, G.E. (2019). Physics-informed neural networks: a deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378, 686–707.

- [2] Karniadakis, G.E., Kevrekidis, I.G., Lu, L., Perdikaris, P., Wang, S., & Yang, L. (2021). Physics-informed machine learning. *Nature Reviews Physics*, 3, 422–440.
- [3] Chen, X. et al. (2021). Solving inverse stochastic problems from discrete particle observations using the Fokker-Planck equation and physics-informed neural networks. *SIAM Journal on Scientific Computing*.
- [4] Krishnapriyan, A.S. et al. (2021). Characterizing possible failure modes in physics-informed neural networks. *Advances in Neural Information Processing Systems*, 34.